

Analisis Komparatif Performa Jaringan Konvolusi Klasifikasi Citra Biner: CNN From Scratch vs Transfer Learning MobileNetV2

*Tugas Individu - Praktikum Pembelajaran Mesin 2

Muhammad Dafi Al Haq
Program Studi Teknik Informatika, Fakultas Sains dan Teknologi
Universitas Darussalam Gontor
Ponorogo, Indonesia
NIM: 452024611067 — Semester: 5
Email: m.dafi@unida.gontor.ac.id

Abstract—Eksperimen komparatif ini menguji performa klasifikasi citra dua kelas menggunakan dua pendekatan deep learning yang berbeda: Jaringan Konvolusi dari dasar (CNN From Scratch) dan Transfer Learning memanfaatkan pretrained model MobileNetV2. Pengujian dijalankan di bawah arsitektur hardware GPU Tesla T4 pada ekosistem Kaggle. Dataset CIFAR-10 direduksi secara taktis untuk klasifikasi biner Airplane vs Automobile, sementara Oxford-IIT Pets direduksi khusus untuk skenario Cats vs Dogs dengan mematuhi rasio pembagian data 70% training, 15% validation, dan 15% testing. Berdasarkan pengujian empiris, CNN from scratch mencapai tingkat akurasi testing tertinggi sebesar 95,67% berkat suplai volume data latih yang masif (12.000 citra). Sebaliknya, Transfer Learning MobileNetV2 meraih akurasi testing sebesar 93,33% dengan efisiensi data ekstrem (1.000 citra). Hasil ini mengonfirmasi superioritas transfer learning pada keterbatasan sampel data, serta ketajaman CNN from scratch pada himpunan data besar berdomain spesifik.

Index Terms—CNN from Scratch, Transfer Learning, MobileNetV2, CIFAR-10, Oxford-IIT Pets, Klasifikasi Biner

I. PENDAHULUAN

Ekstraksi pola spasial dalam rekayasa visi komputer modern menuntut optimasi komputasi yang tinggi. Dalam pengerjaan proyek deep learning, penentuan pendekatan arsitektur sering dihadapkan pada dua pilihan ekstrem: membangun arsitektur konvolusi manual dari nol untuk adaptasi domain lokal secara penuh, atau memanfaatkan abstraksi fitur universal dari pretrained model skala besar yang telah dilatih pada kluster ImageNet.

Laporan ini menyajikan analisis performa empiris dari kedua pendekatan tersebut menggunakan kerangka kerja PyTorch secara objektif. Melalui pembedahan grafik konvergensi loss, akurasi pengujian, beban parameter komputasi, serta Confusion Matrix, penelitian ini ditujukan untuk menetapkan standarisasi pengambilan keputusan arsitektural yang rasional pada domain industri riil.

II. TUJUAN PEMBELAJARAN

Eksperimen terkontrol ini ditujukan untuk mengunci beberapa indikator kompetensi utama, antara lain:

- Mengimplementasikan arsitektur CNN manual dari awal yang adaptif terhadap citra berwarna (RGB) 3-channel.
- Mengonfigurasi arsitektur MobileNetV2 menggunakan strategi *Feature Extraction* dengan membekukan bobot parameter konvolusi dasar.
- Mengevaluasi kestabilan pelatihan, kurva loss, akurasi, serta memetakan matriks kebingungan (Confusion Matrix).
- Memformulasikan argumentasi teknis berbasis hasil pengujian riil dalam menyelesaikan studi kasus struktural.

III. DESKRIPSI DATASET

Penelitian ini menggunakan dua jenis repositori data visual dengan karakteristik dimensi spasial dan volume yang berbeda:

A. Dataset CIFAR-10 (Eksperimen CNN from Scratch)

Dataset ini tersusun atas gambar berwarna berdimensi 32×32 piksel. Pemisahan taktis dilakukan untuk mengisolasi Kelas 0 (*Airplane*) dan Kelas 1 (*Automobile*), menghasilkan total himpunan sampel data biner sebanyak 12.000 citra.

B. Dataset Oxford-IIT Pets (Eksperimen Transfer Learning)

Dataset ini merepresentasikan objek fauna dunia nyata dengan variasi latar belakang yang kompleks. Data difilter untuk mengambil 500 sampel citra Kucing dan 500 sampel citra Anjing, membentuk total subset biner terisolasi sebesar 1.000 citra.

IV. PREPROCESSING DATA

Rekonstruksi data masukan dikonfigurasi secara ketat memakai modul *torchvision.transforms* demi menjaga stabilitas pembelajaran gradien:

- 1) **Transformasi CIFAR-10:** Citra dikonversi menjadi format Tensor dan dinormalisasi menggunakan rata-rata

(mean) dan standar deviasi sebesar 0.5 untuk menyeimbangkan nilai piksel pada rentang $[-1, 1]$.

- 2) **Transformasi Oxford-IIT Pets:** Citra mentah wajib melalui tahapan transformasi spasial *Resize* ke resolusi 224×224 piksel agar kongruen dengan sasis *receptive field* MobileNetV2. Normalisasi dilakukan berbasis parameter ImageNet, yakni $\mu = [0.485, 0.456, 0.406]$ dan $\sigma = [0.229, 0.224, 0.225]$.
- 3) **Isolasi Data (Data Splitting):** Pembagian subset data mengikat rasio distribusi 70% untuk Training, 15% untuk Validation, dan 15% untuk Testing dengan seed acak 42 untuk menjamin replikasi sistem. Hasil pembagian volumetrik disajikan pada Tabel I.

TABLE I
DISTRIBUSI VOLUMETRIK ISOLASI DATASET EKSPERIMEN

Sub-Dataset	CNN from Scratch	Transfer Learning
Training (70%)	8.400 citra	700 citra
Validation (15%)	1.800 citra	150 citra
Testing (15%)	1.800 citra	150 citra
Total	12.000 citra	1.000 citra

V. IMPLEMENTASI CNN FROM SCRATCH

Arsitektur konvolusi manual dibangun menggunakan kelas sekuensial PyTorch dengan mengedepankan efisiensi ekstraksi pola lokal:

- **Blok Fitur 1:** Jaringan menerima input gambar RGB 3-channel. Lapisan `Conv2d(3, 32, kernel_size=3, padding=1)` dikombinasikan dengan `BatchNorm2d(32)` untuk stabilitas aktivasi, fungsi non-linear `ReLU`, dan `MaxPool2d(2)` yang mereduksi dimensi spasial awal gambar menjadi 16×16 .
- **Blok Fitur 2:** `Conv2d(32, 64, kernel_size=3, padding=1)`, `BatchNorm2d(64)`, aktivasi `ReLU`, dan `MaxPool2d(2)` yang menghasilkan reduksi dimensi spasial akhir sebesar 8×8 .
- **Blok Klasifikasi:** Jaringan tensor diratakan via `Flatten` menjadi dimensi linier datar sebesar $64 \times 8 \times 8 = 4.096$ elemen. Dihubungkan menuju `Linear Layer` dengan 128 neuron, disusun regularisasi agresif `Dropout(0.5)` untuk mengunci model dari overfitting, dan diakhiri `Linear(128, 2)` sebagai proyeksi klasifikasi biner.

VI. IMPLEMENTASI TRANSFER LEARNING

Metodologi transfer learning mengimplementasikan arsitektur pretrained model **MobileNetV2** bawaan PyTorch Hub:

- **Justifikasi Pemilihan Model:** MobileNetV2 dirancang menggunakan arsitektur *Inverted Residuals* dan *Depth-wise Separable Convolution* yang memangkas parameter operasi perkalian matriks secara drastis, menjadikannya arsitektur yang sangat ringan (*lightweight*) dengan akurasi generalisasi visual yang matang.
- **Strategi Pembekuan (Feature Extraction):** Seluruh parameter gradien pada sasis fitur dasar

dikunci secara penuh menggunakan perintah `param.requires_grad = False`. Langkah ini menjamin bobot filter universal ImageNet tidak akan mengalami perubahan sepanjang proses pelatihan lokal.

- **Modifikasi Klasifikasi:** Lapisan *classifier* bawaan diganti dengan blok `Sequential` baru yang mempertemukan `Dropout(0.2)` dan `Linear(1280, 2)` guna memetakan fitur global menjadi skor logit biner Kucing vs Anjing.

VII. HASIL EKSPERIMEN

Kedua arsitektur dilatih menggunakan kriteria loss `CrossEntropyLoss` dan optimizer Adam dengan nilai *learning rate* konstan 0,001 sepanjang 5 epoch di atas hardware akselerator GPU Tesla T4 Kaggle. Log numerik historis pelatihan terekam secara nyata pada Tabel II.

TABLE II
LOG HISTORIS PERFORMA PELATIHAN SEPANJANG 5 EPOCH

Epoch	Scratch Acc	Scratch Loss	Transfer Acc	Transfer Loss
1	82,45%	0,4295	75,29%	0,5641
2	90,06%	0,2400	85,86%	0,3981
3	92,17%	0,1928	89,43%	0,3222
4	93,60%	0,1618	89,71%	0,2970
5	94,85%	0,1351	90,57%	0,2741

VIII. PERBANDINGAN MODEL DAN ANALISIS METRIK

Evaluasi komparatif akhir secara menyeluruh disajikan pada Tabel III. Data membuktikan kedua arsitektur berhasil mengonvergensi bobot parameter dengan performa pengujian di atas 93%.

TABLE III
MATRIKS KOMPARASI PERFORMA OBJEKTIF AKHIR

Metrik Evaluasi	CNN from Scratch	Transfer Learning
Akurasi Training	94,85%	90,57%
Akurasi Validation	94,50%	88,00%
Akurasi Testing	95,67%	93,33%
Loss Training	0,1351	0,2741
Loss Validation	0,1341	0,2714
Kecepatan Iterasi	Sangat Cepat (~83 it/s)	Moderat (~10 it/s)
Volume Dataset	Masif (12.000 citra)	Minim (1.000 citra)
Risiko Overfitting	Sangat Rendah	Rendah

A. Analisis Kurva Loss dan Akurasi

Model CNN *from scratch* memperlihatkan konvergensi yang sangat ideal. Kurva pelatihan dan validasi berhimpit secara konsisten tanpa ada jarak (*gap*) lebar. Fenomena ini didorong oleh ketersediaan volume data CIFAR-10 lokal yang melimpah (8.400 data latih), mematangkan penyusunan filter dari nol tanpa terjankit gejala *overfitting*. Pada model Transfer Learning, performa akurasi melonjak tajam sejak epoch awal dan stabil di area 93% pada pengujian akhir data uji.




Fig. 1. Kurva Komparasi Tren Akurasi dan Loss antara CNN From Scratch dan Transfer Learning selama 5 Epoch.

B. Analisis Confusion Matrix Uji Akhir

Hasil ekstraksi matriks kebingungan pada data testing yang diuji langsung pada model menghasilkan metrik distribusi berikut:

- **CNN From Scratch (Testing: 1.800 Citra):** Model menghasilkan nilai *True Positive* (Pesawat diprediksi benar) sebesar **882**, dan *True Negative* (Mobil diprediksi benar) sebesar **840**. Kasus salah klasifikasi tercatat sangat rendah, yakni 43 citra pesawat diprediksi mobil dan 35 citra mobil diprediksi pesawat.
- **Transfer Learning (Testing: 150 Citra):** Model memproduksi nilai prediksi benar sebesar **68** untuk Kucing dan **72** untuk Anjing. Kasus salah prediksi tercatat minim, di mana model hanya keliru mendeteksi 3 citra kucing sebagai anjing dan 7 citra anjing sebagai kucing.

```

=== METRIK EVALUASI TESTING: CNN From Scratch ===
Akurasi Data Akhir (Testing): 95.67%
Confusion Matrix:
[[882 43]
 [ 35 840]]

=== METRIK EVALUASI TESTING: Transfer Learning ===
Akurasi Data Akhir (Testing): 93.33%
Confusion Matrix:
[[68  3]
 [ 7 72]]

```

Fig. 2. Hasil Output Matriks Kebingungan (Confusion Matrix) Pengujian Data Uji Akhir.

IX. ANALISIS STRATEGIS: KAPAN MEMILIH CNN VS TRANSFER LEARNING?

Eksperimen empiris ini memberikan landasan logika transparan untuk menentukan keputusan rekayasa sistem visi komputer di industri nyata:

- 1) **Ukuran Kuantitas Dataset:** Apabila dataset lokal berukuran kecil (di bawah 10.000 sampel), mengimplementasikan Transfer Learning dengan mengunci layer dasar adalah pilihan mutlak demi menepis kegagalan latihan. Sebaliknya, jika data melimpah (ratusan ribu sampel), melatih CNN dari nol menjadi rasional untuk dikerjakan.
- 2) **Karakteristik Kemiripan Domain:** Jika target objek visual memiliki kemiripan geometri dengan ImageNet (hewan, kendaraan, benda umum), Transfer Learning memberikan akurasi tinggi secara instan. Namun, jika domain bersifat ultra-spesifik (misalnya citra

mikroskopis sel kanker atau citra satelit radar), melatih model dari awal atau melakukan strategi *Fine-Tuning* jauh lebih superior.

- 3) **Batasan Sumber Daya Komputasi:** Transfer Learning memangkas siklus waktu latihan secara signifikan karena parameter yang memerlukan kalkulasi gradien hanyalah bagian *classifier head* paling ujung, menghemat komputasi hardware secara drastis.

X. JAWABAN STUDI KASUS PENGAMBILAN KEPUTUSAN

Berdasarkan hukum arsitektur deep learning, berikut adalah resolusi keputusan untuk 4 skenario dunia nyata:

- **Skenario 1 (Klinik Medis - 300 Citra Radiologi):** Pendekatan terbaik adalah **Transfer Learning**. Melatih CNN dari dasar dengan 300 gambar akan memicu kegagalan sistem akibat *overfitting* parah. Pengetahuan filter dari *pretrained weights* bertindak sebagai landasan kokoh untuk mengekstrak anomali tekstur medis.
- **Skenario 2 (Perusahaan Ritel - 1 Juta Citra Produk Internal):** Pendekatan terbaik adalah **CNN from Scratch**. Volume data sebesar 1 juta sampel sepenuhnya melenyapkan ancaman *overfitting*. Mengingat produk ritel internal bersifat non-ImageNet, melatih filter dari nol akan menghasilkan model yang memiliki akurasi paling adaptif.
- **Skenario 3 (Prototipe Perusahaan Startup - Batas Waktu 2 Hari, 500 Citra):** Pendekatan terbaik adalah **Transfer Learning (Feature Extraction)**. Hambatan utama dalam skenario ini adalah efisiensi waktu dan minimnya data. Metode *Feature Extraction* dapat diselesaikan dalam hitungan menit di atas sasis MobileNetV2 demi menghindari penundaan rilis produk.
- **Skenario 4 (Tim Riset Otonom - Dataset Masif, GPU Melimpah, Citra Spesifik):** Pendekatan terbaik adalah **Transfer Learning dengan Metode Fine-Tuning**. Menggunakan *pretrained weights* sebagai titik awal (*Weight Initialization*) kemudian membuka kunci lapisan konvolusi tingkat atas untuk dilatih kembali secara perlahan akan menghasilkan performa model paling optimal dengan konvergensi cepat.

XI. PERTANYAAN REFLEKSI PRIBADI

- 1) *Apa tantangan terbesar saat mengerjakan tugas ini?*
Tantangan terbesar terletak pada pembentukan *data pipeline* lokal yang harus berjalan secara paralel menggunakan parameter `num_workers=2` pada Kaggle, serta sinkronisasi dimensi spasial matriks tensor dari dataset Oxford Pets agar presisi masuk ke dalam *classifier* MobileNetV2 tanpa memicu error *mismatch*.
- 2) *Bagian mana yang paling sulit: CNN from scratch atau transfer learning? Mengapa?*
CNN *from scratch*. Pendekatan ini menuntut kalkulasi matematis manual yang teliti terhadap perubahan dimensi *feature map* setelah melewati operasi filter konvolusi dan pooling agar dapat ditransformasikan secara tepat saat proses *flattening* menuju *fully connected layer*.

- 3) *Apa perbedaan paling terasa antara melatih model dari awal dan menggunakan pretrained model?*

Kecepatan konvergensi dan tingkat kematangan model. Model *Transfer Learning* langsung memperlihatkan performa akurasi yang tinggi dan loss yang rendah sejak epoch pertama karena sasis fiturnya sudah terlatih mengenali pola visual ImageNet. Sementara CNN *from scratch* membutuhkan waktu iterasi bertahap untuk menempa bobot acak menjadi filter visual yang bermakna.

- 4) *Jika tugas ini digunakan untuk kasus nyata, pendekatan mana yang akan Anda pilih?*

Transfer Learning. Ditinjau dari sudut pandang efisiensi industri, pendekatan ini memberikan ROI performa paling kompetitif, menghemat konsumsi energi komputasi, meminimalkan kebutuhan volume pengumpulan data mentah, dan memotong siklus waktu *time-to-market* produk AI.

- 5) *Apa hal baru yang Anda pelajari tentang pengambilan keputusan dalam deep learning?*

Saya mempelajari bahwa kecerdasan artifisial adalah transaksi nilai yang pragmatis. Model yang dibangun secara megah dari nol tidak akan memberikan hasil bernilai tinggi tanpa suplai volume data yang masif. Pengambilan keputusan arsitektural yang matang wajib menyeimbangkan tiga batasan dingin secara transparan: kuantitas data lokal, kemiripan domain objek, serta ketersediaan resource infrastruktur komputasi.

XII. KESIMPULAN

Eksperimen ini berhasil memvalidasi komparasi performa klasifikasi citra biner secara akurat. CNN *from scratch* unggul dengan akurasi 95,67% memanfaatkan keunggulan data masif, sedangkan Transfer Learning MobileNetV2 membuktikan dominasi efisiensinya dengan meraih akurasi 93,33% di tengah keterbatasan data yang ekstrem. Kedua metodologi ini merupakan aset bernilai tinggi dalam pengembangan sistem deep learning modern jika diaplikasikan sesuai arsitektur strategi yang tepat.